

Obtendo dados do Ipeadata via API

Extraindo os dados

Este tutorial visa auxiliar pesquisadores a coletar bases de dados do Ipeadata disponíveis em sua API. Em sua essência, este repositório possui três scripts principais: **`ipeadata_query`**, **`ipeadata_url`** e **`ipeadata_api`**. As duas últimas funções atuam em conjunto como a engrenagem para obtenção das bases de dados. Se por um lado **`ipeadata_url`** atua na criação das URLs onde os dados estão localizados, por outro **`ipeadata_api`** é responsável por extrair a informação lá localizada. Por fim, a função **`ipeadata_query`** combina estas duas funções em uma única interface, tornando simples o processo de extração de dados.

```
ipeadata_query(ipeadata_series_code, ipeadata_series_name, time_interval, source_github = TRUE)
```

Os argumentos da função **`ipeadata_query`** são:

- `ipeadata_series_code`: código das séries a serem extraídas.
- `ipeadata_series_name`: nome das séries a serem extraídas.
- `time_interval`: período¹ (ano) correspondente ao dado a ser extraído.
- `source_github`: Este argumento é opcional e permite ao pesquisador escolher acessar a função diretamente deste diretório ou de uma cópia das funções disponíveis em sua máquina local.

Vejamos um exemplo. Suponha que desejamos coletar os dados referente ao Índice de Preços (IPCA) e ao PIB brasileiro no período 2015-2025. Enquanto a série de preços possui frequência mensal, o PIB possui frequência anual.

```
# ===== #  
# === Data Extraction === #  
# ===== #
```

¹Certamente, existem diversas bases de dados com diferentes frequências. No entanto, para uma extração padronizada o código somente irá filtrar os dados baseado no ano da série.

```
# --- Ipeadata Query Function --- #
source('https://raw.githubusercontent.com/paulo-icaro/Ipeadata_API/refs/heads/main/ipeadata_query.R')

# --- Previous Info --- #
series_code = c('PRECOS12_IPCA12', 'WEO_PIBWEOBRA')
series_name = c('br_price_index', 'br_gdp')
period = as.character(x = 2015:2025)

database = ipeadata_query(series_code, series_name, period, source_github = TRUE)
print(head(database, 15), row.names = FALSE)
```

	data	br_price_index	br_gdp
2015-01-01T00:00:00-02:00		4110.20	1800.046
2015-02-01T00:00:00-02:00		4160.34	NA
2015-03-01T00:00:00-03:00		4215.26	NA
2015-04-01T00:00:00-03:00		4245.19	NA
2015-05-01T00:00:00-03:00		4276.60	NA
2015-06-01T00:00:00-03:00		4310.39	NA
2015-07-01T00:00:00-03:00		4337.11	NA
2015-08-01T00:00:00-03:00		4346.65	NA
2015-09-01T00:00:00-03:00		4370.12	NA
2015-10-01T00:00:00-03:00		4405.95	NA
2015-11-01T00:00:00-02:00		4450.45	NA
2015-12-01T00:00:00-02:00		4493.17	NA
2016-01-01T00:00:00-02:00		4550.23	1796.622
2016-02-01T00:00:00-02:00		4591.18	NA
2016-03-01T00:00:00-03:00		4610.92	NA

O fato das duas séries terem frequências temporais diferentes implica em um conjunto de dados desigual. Esse ponto, contudo, não será um problema desde que alguns cuidados sejam tomados. Neste exemplo, a base de dados final possui 131 observações mensais e 10 observações anuais, cada uma correspondendo ao primeiro mês de cada ano. Nessas circunstâncias, não haverá problema em razão de que todos os dados foram acessados.

Entretanto, caso a ordem de especificação das variáveis estivesse invertida (PIB e IPCA), teríamos um problema considerável. Nesse caso, o conjunto de dados final teria somente 10 observações no total, onde somente a primeira observação mensal de cada ano seria aproveitada para o caso da série de preços.

Dessa maneira duas soluções para contornar o problema surgem:

- Ao informar as séries a serem coletadas, a ordem de definição das variáveis devem sempre ser feita de modo que as séries de alta-frequência sejam sempre priorizadas.

- Importar séries juntas de acordo com sua frequência temporal. Nessa alternativa será necessário utilizar a função **ipeadata_query** mais de uma vez.